НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
“КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО”

Навчання нейронних мереж з підкріпленням

Методичні вказівки для виконання практичних робіт | Осінній семестр

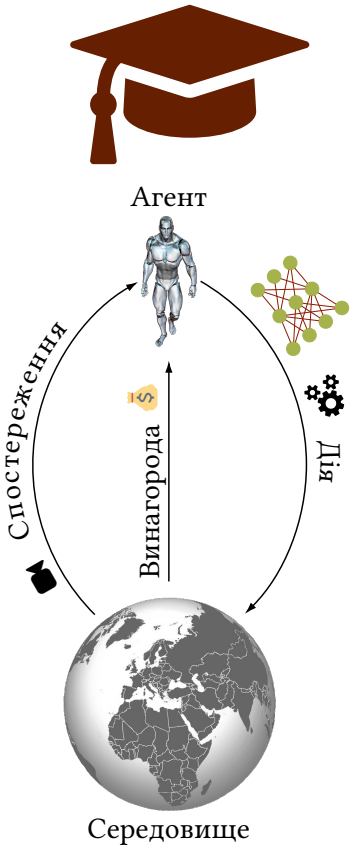

Q-навчання

“Невдачі неодмінно будуть, і те, як ви з ними впораєтеся,
буде найважливішим показником того, чи досягнете ви успіху.”

– Джеймі Даймон

Опис завдання

Агент має знайти вихід з лабіринту, уникаючи перешкод. Для цього розробіть агента, який зможе вивчити оптимальний шлях в лабіринті, використовуючи алгоритм Q-навчання.

Нижче подано приклад простого середовища для лабіринту. Для візуалізації використано текстову графіку та лінійну структуру для руху агента.

```python
import numpy as np
import random

class MazeEnv:
    def __init__(self, size=5):
        # Ініціалізуємо лабіринт розміром size x size
        self.size = size
        self.maze = self._generate_maze()
        self.agent_pos = [0, 0]
        self.goal_pos = [size - 1, size - 1]
        self.done = False
        self.actions = ['up', 'down', 'left', 'right']

    def _generate_maze(self):
        # Створюємо лабіринт з перешкодами
        maze = np.zeros((self.size, self.size), dtype=int)
        num_obstacles = int(self.size * self.size * 0.2)
        obstacles = random.sample(range(1, self.size * self.size - 1), num_obstacles)
        for obs in obstacles:
            maze[obs // self.size][obs % self.size] = 1
        return maze

    def reset(self):
        # Повертаємо лабіринт до початкового стану
        self.agent_pos = [0, 0]
        self.done = False
        return self.agent_pos

```

```
    def step(self, action):
        # Рухаємо агента залежно від вибраної дії
        if action not in self.actions:
            raise ValueError(f"Invalid action {action}. Use: {self.actions}")

        x, y = self.agent_pos

        if action == 'up' and x > 0:
            x -= 1
        elif action == 'down' and x < self.size - 1:
            x += 1
        elif action == 'left' and y > 0:
            y -= 1
        elif action == 'right' and y < self.size - 1:
            y += 1

        if self.maze[x][y] == 1:
            # Якщо перешкода, повертаємо на попереднє місце
            return self.agent_pos, -1, False

        self.agent_pos = [x, y]

        if self.agent_pos == self.goal_pos:
            self.done = True
            return self.agent_pos, 10, True

        return self.agent_pos, -0.1, False

    def render(self):
        # Виводимо лабіринт і позицію агента
        maze_copy = np.copy(self.maze)
        x, y = self.agent_pos
        maze_copy[x][y] = 2
        maze_copy[self.goal_pos[0]][self.goal_pos[1]] = 3
        print(maze_copy)

# Використання середовища
env = MazeEnv(size=5)
env.reset()
env.render()

# Приклад кроків агента
actions = ['down', 'down', 'right', 'right', 'right', 'up', 'up', 'right']
for action in actions:
    pos, reward, done = env.step(action)
    print(f"Position: {pos}, Reward: {reward}, Done: {done}")
    env.render()
    if done:
        print("Agent reached the goal!")
        break
```

```
[[2 0 0 0 1]
 [0 0 0 0 0]
 [0 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [1, 0], Reward: -0.1, Done: False
[[0 0 0 0 1]
 [2 0 0 0 0]
 [0 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [2, 0], Reward: -0.1, Done: False
[[0 0 0 0 1]
 [0 0 0 0 0]
 [2 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [2, 1], Reward: -0.1, Done: False
[[0 0 0 0 1]
 [0 0 0 0 0]
 [0 2 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [2, 1], Reward: -1, Done: False
[[0 0 0 0 1]
 [0 0 0 0 0]
 [0 2 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [2, 1], Reward: -1, Done: False
[[0 0 0 0 1]
 [0 0 0 0 0]
 [0 2 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [1, 1], Reward: -0.1, Done: False
[[0 0 0 0 1]
 [0 2 0 0 0]
 [0 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [0, 1], Reward: -0.1, Done: False
[[0 2 0 0 1]
 [0 0 0 0 0]
 [0 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
Position: [0, 2], Reward: -0.1, Done: False
[[0 0 2 0 1]
 [0 0 0 0 0]
 [0 0 1 0 0]
 [1 0 1 0 0]
 [0 0 0 1 3]]
```

MazeEnv – це клас, що моделює середовище лабіринту. Лабіринт задається у вигляді матриці, де 0 – вільний простір, 1 – перешкода, 2 – агент, а 3 – мета (вихід). Агент починає з позиції $[0, 0]$, а мета знаходиться в позиції $[size - 1, size - 1]$. Для переміщення по лабіринту агент може використовувати такі дії: up, down, left, right. Метод **step** дозволяє агенту рухатись у вибраному напрямку. Якщо рух призводить до зіткнення з перешкодою, агент залишається на місці і отримує винагороду -1. Якщо агент досягає мети, гра завершується і надається винагорода 10. Метод **render** виводить лабіринт у вигляді матриці, де можна бачити, як рухається агент.

Завдання для виконання

Відкрийте завдання:

https://nbviewer.org/github/YKochura/rl-kpi/blob/main/practice/practice1/Maze.ipynb

Вам потрібно імплементувати кілька функцій, які будуть реалізовувати алгоритм Q-навчання. Використовуючи алгоритм Q-навчання навчіть агента знаходити оптимальний шлях (вихід) з лабіринту. Функції, які потрібно імплементувати позначено у завданні так:

```
# TODO
```

Розміщуйте свою реалізацію між рядками:

```
# BEGIN_YOUR_CODE

# END_YOUR_CODE
```

0.0.1 Алгоритм Q-навчання

Алгоритм Q-навчання (Q-learning) є методом навчання з підкріпленням, який дозволяє агенту навчитися знаходити оптимальну стратегію для прийняття рішень у середовищі. Агент використовує Q-таблицю, щоб оцінити, яку дію йому краще виконати в кожному стані. Цей алгоритм добре підходить лише для середовищ з невеликим дискретним простором станів для яких Q-таблиця є невеликою.

1. **Ініціалізація Q-таблиці.** Це таблиця розміром $n \times m$, де n – кількість станів, а m – кількість можливих дій у заданому стані. Значення таблиці оновлюється на основі винагороди, яку агент отримує за виконану дію в поточному стані. На початку всі значення Q-таблиці зазвичай ініціалізуються нулями або невеликими випадковими значеннями:

$$Q(s, a) = 0 \quad \forall\ s \in S, a \in A,$$

   де s – стан у якому знаходиться агент, a – дія, яку виконує агент у цьому стані.

2. **Вибір початкового стану**. Епізод починається з деякого початкового стану s_0. Зазвичай агент починає взаємодію з середовищем з деякого фіксованого стану, але у загальному випадку, початковий стан можна обирати випадковим чином на початку кожного епізоду.

3. **Вибір дії за стратегією**. Для вибору дій агент буде використовувати ε-жадібну стратегію. Якщо випадкове число менше за ε, агент обирає випадкову дію (exploration), щоб дослідити середовище, інакше – використовує набуті знання та обирає найкращу дію a^* (exploitation) на основі поточних значень Q-таблиці:

$$a^* = \arg\max_a Q(s, a) \qquad \forall a_i \in A$$

   Таким чином, агент балансує між вивченням середовища та використанням раніше набутого досвіду.

4. **Отримання винагороди.** Після виконання кожної дії агент переходить у нових стан та отримує за це винагороду.

5. **Оновлення Q-таблиці.** Після кожного кроку агент оновлює значення Q-таблиці для поточного стану та вибраної дії. Оновлення відбувається за правилом:

$$Q(s,a) \leftarrow Q(s,a) + \alpha(r + \gamma \max_{a'} Q(s',a') - Q(s,a)),$$

де α – швидкість навчання, який визначає, наскільки сильно буде оновлюватись значення Q-таблиці, r – винагорода за виконану дію, γ – коефіцієнт знецінювання, який визначає важливість майбутніх винагород, $\max_{a'} Q(s',a')$ – максимальне значення Q-функції для наступного стану s', яке агент може отримати, якщо виконає дію a'.

Приклад: Нехай агент знаходиться у деякому стані s, виконує дію a, за що отримує від середовища винагороду $r = 5$ і переходить у новий стан s'. У новому стані s' агент може виконати як і раніше кілька допустимих дій, але максимальне Q-значення принесе агенту лише одна дія a'. Нехай для нового стану s' максимальне Q-значення становить 10. Якщо швидкість навчання $\alpha = 0.1$, а коефіцієнт знецінювання $\gamma = 0.9$, тоді оновлення виглядатиме так:

$$Q(s,a) \leftarrow Q(s,a) + 0.1 \cdot (5 + 0.9 \cdot 10 - Q(s,a))$$

Якщо поточне $Q(s,a) = 2$, то:

$$Q(s,a) \leftarrow 2 + 0.1 \cdot (5 + 0.9 \cdot 10 - 2) = 3.2$$

6. **Тренування агента.** Агент проходить кілька епізодів (циклів), де намагається досягти мети, навчаючись на власних помилках і оновлюючи свою стратегію. Агент поступово навчиться визначати оптимальні Q-значення для кожної пари стан-дія.

Оцінювання

Максимальна оцінка за виконання завдання – 10 балів.

Здача завдання

Відправляйте завдання на перевірку сюди: https://cloud.comsys.kpi.ua/s/yMty3QrYN9Fd9cc

- потрібно надіслати відпрацьований блокнот, який буде містити реалізовані Вами функції:

  `Прізвище Ім'я_група_Maze.ipynb`

Дедлайн: 12 жовтня 2025 року о 23:59